

Utilizarea SVD pentru detectarea riscului de infarct miocardic (Documentație)

Rusănescu Gabriel (Grupa 161)
Sandu-Popa Eduard-Octavian (Grupa 164)

30 mai 2026

Rezumat

Descompunerea valorilor singulare sau SVD (*Singular value decomposition*) este o unealtă foarte puternică pentru simplificarea datelor. Aceasta constă în luarea unei matrice de numere reale A și a o scrie ca un produs de trei matrici $U\Sigma V^T$, cea din mijloc diagonală (modulo niște linii/coloane de zero) și mult mai ușoară de interpretat decât o matrice obișnuită.

Noi am folosit SVD-ul în această lucrare într-un program scurt de Python pentru a detecta riscului de infarct în funcție de mai mulți parametri cum ar fi vârsta, tensiunea sistolică, dacă persoana este fumătoare sau nu, etc. Aceste date au fost luate dintr-un dataset public de pe Kaggle.

Cuprins

1	Forma unui SVD	2
2	SVD-ul redus	5
3	QR cu reflexii Householder	7
4	Iterația QR	11
5	Tridiagonalizarea Householder	12
6	Algoritmul principal	14
7	Partea de PCA	15

Listă de Algoritmi

1	Factorizarea QR Householder	10
2	Iterația QR	11
3	Tridiagonalizarea Householder	13
4	Descompunerea în valori singulare	14

1 Forma unui SVD

Întrebare. Dacă avem o matrice plină de date, cum o putem duce într-un format mai ușor interpretabil? În cazul nostru, datele sunt informațiile medicale ale mai multor oameni, iar interpretarea ar consta în a estima în ce măsură aceștia riscă să aibă un atac de cord.

Pentru asta vom folosi un concept numit descompunerea în valori singulare a matricei. Pe scurt, aceasta constă în scrierea ei ca un produs de două matrici ortogonale (reflexii și rotații în spațiu) și de o matrice care conține doar valori pe diagonală, numite valori singulare. Utilitatea unui SVD nu este în mod imediat aparentă din definiția și rezultatele de mai jos, dar o teoremă din acest document o va face foarte clară.

Teoremă (Descompunerea valorilor singulare). Fie $m, n \in \mathbb{N}^*$, $r = \min\{m, n\}$ și $A \in \mathcal{M}_{m,n}(\mathbb{R})$. Atunci, există:

- $U \in \mathcal{M}_m(\mathbb{R})$ ortogonală ($UU^\top = I_m$);
- $V \in \mathcal{M}_n(\mathbb{R})$ ortogonală ($VV^\top = I_n$);
- $\sigma_0 \geq \sigma_1 \geq \dots \geq \sigma_{r-1}$ valori singulare reale și matricea $\Sigma \in \mathcal{M}_{m,n}(\mathbb{R})$ dată de

$$\Sigma = \left[\begin{array}{c|c} \text{diag}(\sigma_0, \sigma_1, \dots, \sigma_{r-1}) & O_{r,n-r} \\ \hline O_{r,m-r} & O_{m-r,n-r} \end{array} \right]$$

astfel încât

$$A = U\Sigma V^\top.$$

Demonstrație. Vom folosi demonstrația de la curs: Fie $\mathcal{B} = \{v \in \mathbb{R}^n \mid \|v\|_2 = 1\}$. Avem că $\mathcal{B}$ este frontiera bilei de centru $O_{n,1}$ și rază 1, deci este mulțime compactă. Funcția $f: \mathcal{B} \rightarrow \mathbb{R}$ dată de $f(v) = \|Av\|_2$ pentru orice $v \in \mathcal{B}$ este continuă și domeniul ei este compact, deci este mărginită și își atinge marginile, de unde rezultă că există $v_0 = \underset{v \in \mathcal{B}}{\operatorname{argmax}} f(v) = \underset{\substack{v \in \mathbb{R}^n \\ \|v\|_2=1}}{\operatorname{argmax}} \|Av\|_2$.

Acum definim $\sigma_0 \stackrel{\text{def}}{=} \|Av_0\|_2$.

Caz 1. Dacă $\sigma_0 = 0$ (cazul banal), atunci $A = O_{m,n}$ și evident există U, V și Σ cu proprietățile din teoremă astfel încât $A = U\Sigma V^\top$ și valorile singulare să fie ordonate descrescător.

Caz 2. Altfel, trebuie ca $\sigma_0 > 0$, deci putem defini $u_0 \stackrel{\text{def}}{=} \frac{Av_0}{\sigma_0} = \frac{Av_0}{\|Av_0\|_2}$. Cum $\|u_0\|_2 = \|v_0\|_2 = 1$, folosind procedeul Gram-Schmidt putem să le extindem la două matrici $U \stackrel{\text{def}}{=} [u_0 \mid U_1] \in \mathcal{M}_m(\mathbb{R})$ și $V \stackrel{\text{def}}{=}$

$\begin{bmatrix} v_0 & | & V_1 \end{bmatrix} \in \mathcal{M}_n(\mathbb{R})$ ortogonale. Acum calculăm

$$\begin{aligned} U^\top AV &= \begin{bmatrix} u_0^\top \\ U_1^\top \end{bmatrix} A \begin{bmatrix} v_0 & | & V_1 \end{bmatrix} \\ &= \begin{bmatrix} u_0^\top \\ U_1^\top \end{bmatrix} \begin{bmatrix} Av_0 & | & AV_1 \end{bmatrix} \\ &= \begin{bmatrix} u_0^\top Av_0 & | & u_0^\top AV_1 \\ U_1^\top Av_0 & | & U_1^\top AV_1 \end{bmatrix}. \end{aligned}$$

Cum $u_0 = \frac{Av_0}{\sigma_0}$, avem că $u_0^\top u_0 = \frac{u_0^\top Av_0}{\sigma_0}$. Dar $u_0^\top u_0 = \|u_0\|_2^2 = 1$, deci $u_0^\top Av_0 = \sigma_0$, de unde

$$U^\top AV = \begin{bmatrix} \sigma_0 & | & u_0^\top AV_1 \\ U_1^\top Av_0 & | & U_1^\top AV_1 \end{bmatrix}.$$

Totodată $Av_0 = \sigma_0 u_0$, deci $U_1^\top Av_0 = \sigma_0 U_1^\top u_0 = 0_{m-1,1}$, pentru că toți vectorii lui U_1 ($u_1, u_2, \dots, u_{m-1}$) sunt ortogonali cu u_0 prin definiție, deci notând $\Sigma \stackrel{\text{not}}{=} U^\top AV$, $w \stackrel{\text{not}}{=} V_1^\top A^\top u_0$ și $\Sigma_1 \stackrel{\text{not}}{=} U_1^\top AV_1$ obținem că

$$\Sigma = \begin{bmatrix} \sigma_0 & | & w^\top \\ 0_{m-1,1} & | & \Sigma_1 \end{bmatrix}.$$

Acum ne dorim să arătăm că $w^\top = 0_{1,n-1}$. Avem că:

$$\begin{aligned} \left\| \Sigma \begin{bmatrix} \sigma_0 \\ w \end{bmatrix} \right\|_2 &= \left\| \begin{bmatrix} \sigma_0 & | & w^\top \\ 0_{m-1,1} & | & \Sigma_1 \end{bmatrix} \begin{bmatrix} \sigma_0 \\ w \end{bmatrix} \right\|_2 \\ &= \left\| \begin{bmatrix} \sigma_0^2 + w^\top w \\ \Sigma_1 w \end{bmatrix} \right\|_2 \\ &= \sqrt{(\sigma_0^2 + w^\top w)^2 + \|\Sigma_1 w\|_2^2} \\ &\geq \sigma_0^2 + w^\top w. \end{aligned}$$

Din definiția normei 2 a unei matrici,

$$\begin{aligned} \|\Sigma\|_2 &= \max_{v \in \mathbb{R}^n \setminus \{0_{n,1}\}} \frac{\|\Sigma v\|_2}{\|v\|_2} \geq \frac{\left\| \Sigma \begin{bmatrix} \sigma_0 \\ w \end{bmatrix} \right\|_2}{\left\| \begin{bmatrix} \sigma_0 \\ w \end{bmatrix} \right\|_2} \\ &\geq \frac{\sigma_0^2 + w^\top w}{\sqrt{\sigma_0^2 + w^\top w}} = \sqrt{\sigma_0^2 + w^\top w}. \end{aligned}$$

Avem că

$$\begin{aligned} \sigma_0 &= \|A\|_2 = \|U \Sigma V^\top\|_2 \\ &= \max_{v \in \mathbb{R}^n \setminus \{0_{n,1}\}} \frac{\|U \Sigma V^\top v\|_2}{\|v\|_2} \end{aligned}$$

Cum U și $V^\top$ sunt matrici ortogonale, rezultă că pentru orice $v \in \mathbb{R}^n$, $\|U\Sigma V^\top v\|_2 = \|\Sigma v\|_2$ (ele nu modifică norma lui v în plus față de A , fiind numai rotații și reflexii). Avem deci că

$$\begin{aligned}\sigma_0 &= \max_{v \in \mathbb{R}^n \setminus \{O_{n,1}\}} \frac{\|\Sigma v\|_2}{\|v\|_2} = \|\Sigma\|_2 \\ &\geq \sqrt{\sigma_0^2 + w^\top w},\end{aligned}$$

sau $\sigma_0^2 \geq \sigma_0^2 + w^\top w$, de unde $w^\top w = 0$, deci $w = O_{1,n-1}$. Am obținut:

$$\Sigma = U^\top A V = \left[\begin{array}{c|c} \sigma_0 & O_{1,n-1} \\ \hline O_{m-1,1} & \Sigma_1 \end{array} \right].$$

Repetăm inductiv procedeul pentru $\Sigma_1, \Sigma_2, \dots$ pentru a obține restul de valori singulare $\sigma_1, \sigma_2, \dots, \sigma_{r-1}$.

□

Noi am demonstrat numai existența valorilor singulare și a matricilor ortogonale U și V , dar nu și un mod de a le calcula dată fiind o matrice A . Se poate arăta că valorile singulare pot fi exprimate ca rădăcinile pătrate ale valorilor proprii ori ale lui $AA^\top$, ori ale lui $A^\top A$, iar matricile ortogonale U și V sunt formate din vectorii proprii asociați:

Remarcă. Au loc relațiile $A^\top A v_i = \sigma_i^2 v_i$ și $AA^\top u_i = \sigma_i^2 u_i$, $\forall i \in \overline{0, r-1}$ (σ_i^2 sunt valori proprii pentru matricea $A^\top A$ cu vectorii proprii v_i și pentru matricea $AA^\top$ cu vectorii proprii u_i).

Demonstrație. Știm că $A = U\Sigma V^\top$. Atunci, $AV = U\Sigma$, sau

$$Av_i = u_i \sigma_i, \quad \forall i \in \overline{0, r-1}.$$

Într-un mod asemănător, $A^\top = V\Sigma^\top U^\top$ de unde $A^\top U = V\Sigma^\top$, adică

$$A^\top u_i = \sigma_i v_i, \quad \forall i \in \overline{0, r-1}.$$

Rezultă că $A^\top A v_i = A^\top \sigma_i u_i = \sigma_i^2 v_i$ și $AA^\top u_i = A \sigma_i v_i = \sigma_i^2 u_i$, $\forall i \in \overline{0, r-1}$. □

2 SVD-ul redus

Întrebare. Este posibil să nu vrem să păstrăm chiar toate informațiile dintr-o descompunere în valori singulare din diverse considerente (exemplu: memorie, zgomot, etc). Ne punem atunci întrebarea, dacă ar trebui să eliminăm anumite componente dintr-un SVD, care sunt cele care ar afecta cel mai puțin cantitatea de informație pe care matricea ne-o oferă?

Propoziție. Fie $m, n \in \mathbb{N}^*$ și $A \in \mathcal{M}_{m,n}(\mathbb{R})$. Dacă descompunerea în valori singulare a lui A este $U\Sigma V^\top$ și Σ are r valori singulare strict pozitive pe diagonala principală, atunci $\text{rang } A = r$ (evident).

Teoremă (Eckart-Young). Dacă $k \in \mathbb{N}^*$ astfel încât $k < r$ (rangul matricei A), $\Sigma_k \stackrel{\text{not}}{=} \left[\begin{array}{c|c} \text{diag}(\sigma_0, \sigma_1, \dots, \sigma_{k-1}) & O_{k,n-k} \\ \hline O_{k,m-k} & O_{m-k,n-k} \end{array} \right]$ și $A_k \stackrel{\text{not}}{=} U\Sigma_k V^\top$, atunci

$$\min_{\substack{B \in \mathcal{M}_{m,n}(\mathbb{R}) \\ \text{rang } B = k}} \|A - B\|_2 = \|A - A_k\|_2,$$

i. e. cea mai bună aproximare de rang k a unei matrici este SVD-ul dar cu ultimele $r - k$ valori singulare șterse. Un astfel de SVD se numește SVD redus.

Demonstrație. Demonstrația a fost adaptată din cartea postată pe grupul de Teams. Mai întâi să calculăm efectiv membrul drept. Folosind faptul că U și V sunt ortogonale,

$$\begin{aligned} \|A - A_k\|_2 &= \|U\Sigma V^\top - U\Sigma_k V^\top\|_2 \\ &= \|U(\Sigma - \Sigma_k)V^\top\|_2 \\ &= \|\Sigma - \Sigma_k\|_2. \end{aligned}$$

Avem că pentru orice $v \in \mathbb{R}^n \setminus \{O_{n,1}\}$,

$$\|(\Sigma - \Sigma_k)v\|_2 = \sqrt{\sum_{i=k}^{r-1} \sigma_i^2 v_i^2} \leq \sigma_k \sqrt{\sum_{i=k}^{r-1} v_i^2} \leq \sigma_k \|v\|_2$$

Deci, aplicând definiția normei 2 a unei matrici,

$$\|\Sigma - \Sigma_k\|_2 = \max_{v \in \mathbb{R}^n \setminus \{O_{n-1}\}} \frac{\|(\Sigma - \Sigma_k)v\|_2}{\|v\|_2} \leq \sigma_k.$$

Maximul este atins pentru $v = e_k \in \mathbb{R}^n$, deci $\|A - A_k\|_2 = \sigma_k$.

Acum vrem să arătăm că pentru orice $B \in \mathcal{M}_{m,n}(\mathbb{R})$ cu $\text{rang } B = k$, $\|A - B\|_2 \geq \|A - A_k\|_2$.

Mai întâi, avem că $\text{rang } B + \dim \ker B = \dim \mathbb{R}^n$ de unde rezultă că $\dim \ker B = n - k$. De aici deducem că există o bază a lui $\ker B$ de cardinalitate $n - k$. Folosind Gram-Schmidt, o putem duce într-o bază ortonormată $\mathcal{B} = \{x_0, x_1, \dots, x_{n-k-1}\}$.

Acum, fie $W = \{v_0, v_1, \dots, v_k\}$. Deoarece V are din construcție coloanele ortonormate, rezultă că $\dim \langle W \rangle = k + 1$. Așadar $\dim \ker B + \dim \langle W \rangle = n + 1 =$

$\dim \mathbb{R}^n$. Noi știm și din teorema lui Grassmann că

$$\begin{aligned} n &\geq \dim(\ker B + \dim \langle W \rangle) \\ &= \dim \ker B + \dim \langle W \rangle - \dim(\ker B \cap W), \\ &= n + 1 - \dim(\ker B \cap W). \end{aligned}$$

De aici rezultă că $\dim(\ker B \cap W) \geq 1$, de unde există un $w \in \ker B \cap W \setminus \{0_{n,1}\}$. Putem alege unul cu $\|w\|_2 = 1$. Reiese cum $w \in \langle W \rangle$ că există

$\alpha_0, \alpha_1, \dots, \alpha_k \in \mathbb{R}$ astfel încât $w = \sum_{i=0}^k \alpha_i v_i$, așadar:

$$\begin{aligned} \|A - B\|_2 &\geq \|(A - B)w\|_2 = \|Aw\|_2 = \left\| A \cdot \sum_{i=0}^k \alpha_i v_i \right\|_2 = \left\| \sum_{i=0}^k \alpha_i A_i v_i \right\|_2 \\ &= \left\| \sum_{i=0}^k \alpha_i \sigma_i u_i \right\|_2 = \sqrt{\sum_{i=0}^k \alpha_i^2 \sigma_i^2} \geq \sigma_k \sqrt{\sum_{i=0}^k \alpha_i^2}. \end{aligned}$$

Termenul cu radical dispare, cum rezultă din:

$$1 = \sqrt{w^\top w} = \sqrt{\left(\sum_{i=0}^k \alpha_i v_i^\top \right) \left(\sum_{j=0}^k \alpha_j v_j \right)} = \sqrt{\sum_{i=0}^k \sum_{j=0}^k \alpha_i \alpha_j \underbrace{v_i^\top v_j}_{\delta_{i,j}}} = \sqrt{\sum_{i=0}^k \alpha_i^2}.$$

Deci într-un final $\|A - B\|_2 \geq \sigma_k$. □

3 QR cu reflexii Householder

Întrebare. Cum am putea face oare un SVD să fie și mai rapid și mai stabil numeric, dacă descompunerea QR clasică cu Gram-Schmidt este fix opusul acestor lucruri?

Definiție. Fie $m \in \mathbb{N}^*$ și $v \in \mathbb{R}^m \setminus \{O_{m,1}\}$. Numim matricea (sau transformarea, sau reflexia) Householder asociată lui v matricea

$$H_v = I_m - 2 \frac{vv^\top}{v^\top v}.$$

Propoziție. Câteva proprietăți ale matricei Householder:

1. Este simetrică și ortogonală;
2. Dacă $k \in \overline{1, m}$ și H_{v_k} este matricea Householder asociată unui vector $v_k \in \mathbb{R}^k \setminus \{O_{k,1}\}$, atunci $H_u = \left[\begin{array}{c|c} I_{m-k} & O_{m-k,k} \\ \hline O_{k,m-k} & H_{v_k} \end{array} \right] \in \mathcal{M}_m(\mathbb{R})$ este matricea Householder asociată lui $u = \begin{bmatrix} O_{m-k,1} \\ v_k \end{bmatrix} \in \mathbb{R}^m$;
3. Pentru orice $x \in \mathbb{R}^m \setminus \{O_{m,1}\}$, dacă alegem $\alpha = -\operatorname{sgn}(x_0) \cdot \|x\|_2$ și $v = x - \alpha e_0$, atunci $H_v x = x - 2 \frac{vv^\top}{v^\top v} x = \alpha e_0$ (unde e_0 este primul element din baza canonică a lui $\mathbb{R}^m$). Rezultatul rămâne în mod trivial valabil și dacă în loc de $-\operatorname{sgn}(x_0)$ punem $+\operatorname{sgn}(x_0)$.

Demonstrație. În suportul de curs nu apar justificări, dar toate cele trei proprietăți sunt ușor de demonstrat:

1. Mai întâi verificăm simetria:

$$H_v^\top = I_m^\top - 2 \left(\frac{vv^\top}{v^\top v} \right)^\top = I_m - 2 \frac{vv^\top}{v^\top v} = H_v.$$

Apoi ortogonalitatea:

$$\begin{aligned} H_v^\top H_v &= \left(I_m - 2 \frac{vv^\top}{v^\top v} \right) \left(I_m - 2 \frac{vv^\top}{v^\top v} \right) \\ &= I_m - 4 \frac{vv^\top}{v^\top v} + 4 \frac{v(v^\top v)v^\top}{(v^\top v)^2} \\ &= I_m - 4 \frac{vv^\top}{v^\top v} + 4 \frac{vv^\top}{v^\top v} = I_m; \end{aligned}$$

2. Din calcul:

$$\begin{aligned}
 H_u &= I_m - 2 \cdot \frac{\begin{bmatrix} O_{m-k,1} \\ v_k \end{bmatrix} \begin{bmatrix} O_{1,m-k} & | & v_k^\top \end{bmatrix}}{\begin{bmatrix} O_{1,m-k} & | & v_k^\top \end{bmatrix} \begin{bmatrix} O_{m-k,1} \\ v_k \end{bmatrix}} \\
 &= I_m - 2 \cdot \frac{\begin{bmatrix} O_{m-k} & | & O_{m-k,k} \\ O_{k,m-k} & | & v_k v_k^\top \end{bmatrix}}{v_k^\top v_k} \\
 &= \begin{bmatrix} I_{m-k} & | & O_{m-k,k} \\ O_{k,m-k} & | & H_{v_k} \end{bmatrix};
 \end{aligned}$$

3. Iarăși prin calcul:

$$\begin{aligned}
 H_v x &= x - 2 \frac{v v^\top x}{v^\top v} = x - 2 \frac{v (x^\top - \alpha e_0^\top) x}{(x^\top - \alpha e_0^\top) (x - \alpha e_0)} \\
 &= x - 2 \frac{v (x^\top x - \alpha e_0^\top x)}{x^\top x - \alpha x^\top e_0 - \alpha e_0^\top x + \alpha^2 e_0^\top e_0}.
 \end{aligned}$$

Deoarece $e_0^\top e_0 = 1$, ultimul termen din numitor este α^2 , care la rândul lui este egal cu $\|x\|_2^2$, adică $x^\top x$. Acesta se grupează cu primul $x^\top x$. Totodată $e_0^\top x = x^\top e_0 = x_0$, deci

$$\begin{aligned}
 H_v x &= x - 2 \frac{v (x^\top x - \alpha e_0^\top x)}{2x^\top x - \alpha e_0^\top x - \alpha x^\top e_0} \\
 &= x - 2 \frac{v (x^\top x - \alpha x_0)}{2x^\top x - 2\alpha x_0} \\
 &= x - v = x - (x - \alpha e_0) = \alpha e_0.
 \end{aligned}$$

□

Folosind aceste proprietăți, putem demonstra următorul rezultat legat de scrierea oricărei matrici de numere reale A ca produsul dintre una ortogonală, și una superior triunghiulară ($A = QR$):

Teoremă (Descompunerea QR). *Fie $m, n \in \mathbb{N}^*$ și $A \in \mathcal{M}_{m,n}(\mathbb{R})$. Atunci, există o matrice ortogonală $Q \in \mathcal{M}_m(\mathbb{R})$ și o matrice superior triunghiulară $R \in \mathcal{M}_{m,n}(\mathbb{R})$ astfel încât*

$$A = QR.$$

Demonstrație. Dacă scriem coloanele $A \stackrel{\text{not}}{=} A_0 = \begin{bmatrix} a_0^{(0)} & | & a_1^{(0)} & | & \dots & | & a_{n-1}^{(0)} \end{bmatrix}$ atunci din proprietatea 3 rezultă că pentru $\alpha_0 \stackrel{\text{not}}{=} -\text{sgn} \left(\left(a_0^{(0)} \right)_0 \right) \cdot \left\| a_0^{(0)} \right\|_2$ și $v_0 \stackrel{\text{not}}{=} a_0^{(0)} - \alpha_0 e_0$, are loc $H_{v_0} a_0^{(0)} = a_0^{(0)} - 2 \frac{v_0 v_0^\top}{v_0^\top v_0} a_0^{(0)} = \alpha_0 e_0$ (cu $e_0 \in \mathbb{R}^m$).

Dacă notăm cu $\star$ valorile „nu ne interesează”, atunci

$$\begin{aligned} H_{v_0} A_0 &= \left[\begin{array}{c|c|c|c} \alpha_0 e_0 & H_{v_0} a_1^{(0)} & \dots & H_{v_0} a_{n-1}^{(0)} \end{array} \right] \\ &= \left[\begin{array}{c|ccc} \alpha_0 & \star & \dots & \star \\ 0 & & & \\ \vdots & & A_1 & \\ 0 & & & \end{array} \right]. \end{aligned}$$

Dacă $A_1 \stackrel{\text{not}}{=} \left[\begin{array}{c|c|c|c} a_0^{(1)} & a_1^{(1)} & \dots & a_{n-2}^{(1)} \end{array} \right]$, avem că din proprietatea 3, pentru $\alpha_1 \stackrel{\text{not}}{=} -\text{sgn} \left(\left(a_0^{(1)} \right)_0 \right) \cdot \left\| a_0^{(1)} \right\|_2$ și $v_1 \stackrel{\text{not}}{=} a_0^{(1)} - \alpha_1 e_0$, are loc $H_{v_1} a_0^{(1)} = a_0^{(1)} - 2 \frac{v_1 v_1^\top}{v_1^\top v_1} a_0^{(1)} = \alpha_1 e_0$ (cu $e_0 \in \mathbb{R}^{m-1}$). Notând cu $\tilde{H}_{v_1} = \left[\begin{array}{c|c} 1 & O_{1,m-1} \\ O_{m-1,1} & H_{v_1} \end{array} \right]$, avem că

$$\begin{aligned} \tilde{H}_{v_1} H_{v_0} A_0 &= \left[\begin{array}{c|c} 1 & O_{1,n-1} \\ O_{m-1,1} & H_{v_1} \end{array} \right] \left[\begin{array}{c|ccc} \alpha_0 & \star & \dots & \star \\ 0 & & & \\ \vdots & & A_1 & \\ 0 & & & \end{array} \right] \\ &= \left[\begin{array}{c|ccc} \alpha_0 & \star & \dots & \star \\ 0 & & & \\ \vdots & & H_{v_1} A_1 & \\ 0 & & & \end{array} \right]. \end{aligned}$$

Avem în mod analog că

$$\begin{aligned} H_{v_1} A_1 &= \left[\begin{array}{c|c|c|c} \alpha_1 e_0 & H_{v_1} a_1^{(1)} & \dots & H_{v_1} a_{n-2}^{(1)} \end{array} \right] \\ &= \left[\begin{array}{c|ccc} \alpha_1 & \star & \dots & \star \\ 0 & & & \\ \vdots & & A_2 & \\ 0 & & & \end{array} \right] \end{aligned}$$

De unde

$$\tilde{H}_{v_1} H_{v_0} A = \left[\begin{array}{c|cc|cc} \alpha_0 & 0 & 0 & \dots & 0 \\ 0 & \alpha_1 & \star & \dots & \star \\ 0 & 0 & & & \\ \vdots & \vdots & & A_2 & \\ 0 & 0 & & & \end{array} \right].$$

În mod inductiv, obținem $\tilde{H}_{v_r} \tilde{H}_{v_{r-1}} \dots H_{v_0} A \stackrel{\text{not}}{=} R$ o matrice superior triunghiulară, de unde $r = \min \{m-1, n\}$. Din proprietatea 2 toate matricile $\tilde{H}_{v_k}$ cu $k \in \overline{1, r}$ sunt matrici Householder asociate unor vectori x_k deci din proprietatea 1 sunt ortogonale, deci cum produsul unor matrici ortogonale este tot matrice ortogonală rezultă că acesta este inversabil (în particular la stânga) de unde

$$A = \left(\tilde{H}_{v_r} \tilde{H}_{v_{r-1}} \dots H_{v_0} \right)^\top R = \underbrace{H_{v_0}^\top \tilde{H}_{v_1}^\top \dots \tilde{H}_{v_r}^\top}_Q R,$$

aşadar A se poate scrie ca produsul dintre o matrice ortogonală şi una superior triunghiulară. $\square$

Algoritm 1 Factorizarea QR Householder

Subalgoritm *HouseholderTri* ($A \in \mathcal{M}_m(\mathbb{R})$)

presupunem A simetrică

$Q \leftarrow I_m$; $R \leftarrow A$

Pentru $k \leftarrow 0, \min\{m, n\} - 1$ execută

$x \leftarrow (R_{i,k})_{i \in \overline{k, m-1}}$

$\alpha \leftarrow -\operatorname{sgn}(x_0) \cdot \|x\|_2$ # unde $\operatorname{sgn}(0) = 1$

$v \leftarrow x - \alpha e_0$

Dacă $\min\{\|x\|_2, \|v\|_2, v^\top v\} < 10^{-10}$ atunci

Continuă

SfDacă

$H_v \leftarrow I_{m-k} - 2 \frac{vv^\top}{v^\top v}$

$\tilde{H} \leftarrow \left[\begin{array}{c|c} I_k & O_{k, m-k} \\ \hline O_{m-k, k} & H_v \end{array} \right]$

$Q \leftarrow Q\tilde{H}$; $R \leftarrow \tilde{H}R$

SfPentru

Returnează (Q, R)

SfSubalgoritm

Mai sus avem implementarea factorizării, adaptată de la curs dar cu câteva modificări (semnul lui sgn şi condiţia de continuare).

Notă. Motivul pentru care am ales semnul lui x_0 cu minus este acela că dacă am avea $x_\varepsilon = (1 + \varepsilon, 0, 0, \dots)$ pentru orice $\varepsilon > 0$ atunci $\alpha_\varepsilon = (1 + \varepsilon)^2$ şi $v_\varepsilon = x_\varepsilon - \alpha_\varepsilon e_0 = (\varepsilon - \varepsilon^2, 0, 0, \dots)$.

Pe măsură ce $\varepsilon \rightarrow 0$ avem că $v_\varepsilon^\top v_\varepsilon = (\varepsilon - \varepsilon^2)^2 \rightarrow 0$ şi deci calcularea unei reflexii Householder $I_m - 2 \cdot \frac{v_\varepsilon v_\varepsilon^\top}{v_\varepsilon^\top v_\varepsilon}$ duce la pierderi mari de precizie.

4 Iterația QR

Întrebare. Este important de menționat că în secțiunea 1 („Forma unui SVD”), am vorbit despre cum valorile singulare ale unui SVD se pot găsi calculând doar radicalul valorilor proprii ale lui $A^T A$. Problema cu metoda clasică de a găsi valorile proprii ale unei matrici este că de regulă trebuia să calculăm polinomul caracteristic $\det(A - \lambda I_n)$. Operația aceasta are o complexitate de timp foarte proastă, de $\mathcal{O}(n!)$. Cum am putea găsi valorile proprii ca apoi să găsim valorile și vectorii singulari ai SVD-ului, dacă pentru $n = 1000$ acest lucru deja ar deveni infeasibil?

Algoritm. Există o metodă surprinzător de simplă de a găsi valorile proprii ale unei matrici, și anume iterația QR. Aceasta este descrisă de următorul algoritm:

Algoritm 2 Iterația QR

Subalgoritm $IterQR(A \in \mathcal{M}_{m,n}(\mathbb{R}), tol \in \mathbb{R}_{>0}, maxiter \in \mathbb{N}^*)$

$(Q, T) \leftarrow HouseholderTri(A); V \leftarrow Q$

Pentru $i \leftarrow 0, maxiter - 1$ execută

$E \leftarrow |T - \text{diag}(T)|$

$M \leftarrow \max_{i \neq j} T_{i,j}$

Dacă $M < tol$ atunci

Break

SfDacă

$(Q^*, R^*) \leftarrow HouseholderQR(T)$

$T \leftarrow R^* Q^*; V \leftarrow V Q^*$

SfPentru

Returnează (T, V)

SfSubalgoritm

O singură componentă a acestui algoritm nu am definit-o încă, și anume funcția *HouseholderTri*. Aceasta transformă o matrice A într-un produs dintr-o matrice ortogonală și una tridiagonală. Deoarece $A = QT$, cum transformările ortogonale nu modifică valorile proprii ale unei matrici, avem că valorile proprii ale lui A coincid cu cele ale lui T . Asta ne permite să iterăm QR nu pe A ($\sim n^2$ elemente) ci pe T ($\sim 3n$ elemente) și să obținem aceleași valori singulare într-un timp mai bun.

5 Tridiagonalizarea Householder

Teoremă. Fie $m \in \mathbb{N}^*$ și $A \in \mathcal{M}_m(\mathbb{R})$ simetrică. Atunci, există $Q \in \mathcal{M}_m(\mathbb{R})$ ortogonală astfel încât matricea

$$T = Q^T A Q$$

să fie tridiagonală și simetrică.

Demonstrație. Fie $A_0 \stackrel{\text{not}}{=} A = \left[\begin{array}{c|c} \beta_0 & x_0^T \\ \hline x_0 & A_1 \end{array} \right]$. Din proprietatea 3 a matricilor Householder de la secțiunea „QR cu reflexii Householder”, rezultă că pentru $\alpha_0 = -\text{sgn}((x_0)_0) \cdot \|x_0\|_2$ și $v_0 = x_0 - \alpha_0 e_0^{(m-1)}$ (cu $e_0 \in \mathbb{R}^{m-1}$), are loc relația $H_{v_0} x_0 = x_0 - 2 \frac{v_0 v_0^T}{v_0^T v_0} x_0 = \alpha_0 e_0^{(m-1)}$.

Definim $\tilde{H}_{v_0} = \left[\begin{array}{c|c} 1 & O_{1,m-1} \\ \hline O_{1,m-1} & H_{v_0} \end{array} \right]$ și calculăm $\tilde{H}_{v_0} A H_{v_0}$:

$$\begin{aligned} \tilde{H}_{v_0} A_0 \tilde{H}_{v_0} &= \left[\begin{array}{c|c} 1 & O_{1,m-1} \\ \hline O_{1,m-1} & H_{v_0} \end{array} \right] \left[\begin{array}{c|c} \beta_0 & x_0^T \\ \hline x_0 & A_1 \end{array} \right] \left[\begin{array}{c|c} 1 & O_{1,m-1} \\ \hline O_{1,m-1} & H_{v_0} \end{array} \right] \\ &= \left[\begin{array}{c|c} \beta_0 & x_0^T \\ \hline H_{v_0} x_0 & H_{v_0} A_1 \end{array} \right] \left[\begin{array}{c|c} 1 & O_{1,m-1} \\ \hline O_{1,m-1} & H_{v_0} \end{array} \right] \\ &= \left[\begin{array}{c|c} \beta_0 & x_0^T H_{v_0} \\ \hline H_{v_0} x_0 & H_{v_0} A_1 H_{v_0} \end{array} \right]. \end{aligned}$$

Avem că $x_0^T H_{v_0} = x_0^T H_{v_0}^T$ (din simetria matricelor Householder, proprietatea 1), care mai departe este egal cu $(H_{v_0} x_0)^T$, care am arătat mai sus că este $\alpha_0 e_0^{(m-1)} = [\alpha_0 \mid O_{1,m-2}]$. Deci obținem

$$\tilde{H}_{v_0} A_0 \tilde{H}_{v_0} = \left[\begin{array}{c|c|c} \beta_0 & \alpha_0 & O_{1,m-1} \\ \hline \alpha_0 & & \\ \hline O_{m-1,1} & & H_{v_0} A_1 H_{v_0} \end{array} \right].$$

Inductiv aplicând procedeul pentru $H_{v_0} A_1 H_{v_0}$ obținem că

$$\underbrace{\tilde{H}_{v_{m-3}} \tilde{H}_{v_{m-2}} \dots \tilde{H}_{v_0}}_{Q^T} \underbrace{A \tilde{H}_{v_0} \dots \tilde{H}_{v_{m-2}} \tilde{H}_{v_{m-3}}}_{Q} = \underbrace{\begin{bmatrix} \beta_0 & \alpha_0 & & & \\ \alpha_0 & \beta_1 & \alpha_1 & & \\ & \alpha_1 & \ddots & \ddots & \\ & & \ddots & \beta_{m-2} & \alpha_{m-2} \\ & & & \alpha_{m-2} & \beta_{m-1} \end{bmatrix}}_T.$$

□

Algoritmul de tridiagonalizare urmează aceeași pași ca în demonstrație, modulo niște tehnicalități numerice prezente și în factorizarea QR Householder.

Algoritm 3 Tridiagonalizarea Householder

Subalgoritm *HouseholderTri* ($A \in \mathcal{M}_m(\mathbb{R})$)

```

# presupunem A simetrică
 $Q \leftarrow I_m$ 
 $T \leftarrow A$ 
Pentru  $k \leftarrow \overline{0, m-3}$  execută
     $x \leftarrow (T_{i,k})_{i \in \overline{k+1, m-1}}$ 
     $\alpha \leftarrow -\text{sgn}(x_0) \cdot \|x\|_2$  # unde  $\text{sgn}(0)=1$ 
     $v \leftarrow x - \alpha e_0$ 
    Dacă  $\min\{\|x\|_2, \|v\|_2, v^\top v\} < 10^{-10}$  atunci
        Continuă
    SfDacă
     $H_v \leftarrow I_{m-k-1} - 2 \frac{vv^\top}{v^\top v}$ 
     $\tilde{H} \leftarrow \left[ \begin{array}{c|c} I_{k+1} & O_{k, m-k-1} \\ \hline O_{m-k-1, k} & H_v \end{array} \right]$ 
     $T \leftarrow \tilde{H}T\tilde{H}; Q \leftarrow Q\tilde{H}$ 
    # din motive numerice
     $(T_{i,k})_{i \in \overline{k+2, m-1}} \leftarrow 0$ 
     $(T_{k,i})_{i \in \overline{k+2, m-1}} \leftarrow 0$ 
SfPentru
Returnează  $(Q, T)$ 
SfSubalgoritm

```

De fapt se poate observa că atât algoritmul cât și demonstrația sunt asemănătoare cu cele de la factorizarea QR.

6 Algoritmul principal

Aici este o schiță în pseudocod a descompunerii noastre, cu iterația QR.

Algoritm 4 Descompunerea în valori singulare

```

Subalgoritm  $SVD(A \in \mathcal{M}_{m,n}(\mathbb{R}))$ 

 $(T, V) \leftarrow IterQR(A^T A, 10^{-10}, 10\,000)$ 
# notații coloană
 $U \stackrel{\text{not}}{=} [u_0 \mid \dots \mid u_{m-1}]$ 
 $V \stackrel{\text{not}}{=} [v_0 \mid \dots \mid v_{n-1}]$ 

 $\Lambda \leftarrow \text{diag}(T)$ 
 $ind \leftarrow \text{argsort}(\Lambda, \searrow); \Lambda \leftarrow \Lambda_{ind}$ 
 $S_i \leftarrow \sqrt{\max\{0, \Lambda_i\}}, \forall i \in \overline{0, \ell(\Lambda) - 1}$ 
 $V \leftarrow [v_{ind(0)} \mid \dots \mid v_{ind(n-1)}]$ 
 $U \leftarrow O_m$ 
Pentru  $i \leftarrow \overline{0, \min\{m, n\} - 1}$  execută
    Dacă  $S_i > 10^{-10}$  atunci
         $u_i = \frac{1}{S_i} A v_i$ 
    SfDacă
SfPentru
Pentru  $i \leftarrow \overline{0, m - 1}$  execută
    Dacă  $\|u_i\|_2 < 10^{-10}$  atunci
        Pentru  $k \leftarrow \overline{0, m - 1}$  execută
             $v \leftarrow e_k$  # lungime  $m$ 
            Pentru  $j \leftarrow \overline{0, i - 1}$  execută
                 $v \leftarrow v - (u_j \cdot v) u_j$ 
            SfPentru
            Dacă  $\|v\|_2 > 10^{-10}$  atunci
                 $u_i \leftarrow \frac{v}{\|v\|_2}$ 
            Break
        SfDacă
    SfPentru
SfDacă
 $\Sigma \leftarrow O_{m,n}$ 
Pentru  $i \leftarrow \overline{0, \min\{m, n\} - 1}$  execută
     $\Sigma_{i,i} \leftarrow S_i$ 
SfPentru
Returnează  $(U, \Sigma, V)$ 

SfSubalgoritm

```

7 Partea de PCA

Întrebare. Cum putem elimina redunanța din datele noastre medicale după ce le-am transformat într-o matrice numerică?

Definiție. Fie $m, n \in \mathbb{N}^*$ și fie $X \in \mathcal{M}_{m,n}(\mathbb{R})$. Notăm cu:

1. Media pe coloana j , $\mu_j = \frac{1}{m} \sum_{i=0}^{m-1} X_{i,j}$, $\forall j \in \overline{0, n-1}$;
2. Matricea centrată, $\bar{X} \in \mathcal{M}_{m,n}(\mathbb{R})$ astfel încât $\bar{X}_{i,j} = X_{i,j} - \mu_j$, $\forall i \in \overline{0, m-1}$, $\forall j \in \overline{0, n-1}$;
3. Matricea de covarianță, $\mathcal{C} = \frac{1}{m-1} \bar{X}^\top \bar{X}$.

Afirmație. Putem obține vectorii și valorile proprii ale matricei de covarianță $\mathcal{C}$ aplicând doar un SVD lui $\bar{X}$.

Demonstrație. Fie $U \Sigma V^\top$ SVD-ul lui $\bar{X}$. Atunci,

$$\begin{aligned} \mathcal{C} &= \frac{1}{m-1} \bar{X}^\top \bar{X} = \frac{1}{m-1} (U \Sigma V^\top)^\top (U \Sigma V^\top) = \frac{1}{m-1} V \Sigma^\top U^\top U \Sigma V^\top \\ &= \frac{1}{m-1} V \Sigma^\top \Sigma V^\top. \end{aligned}$$

Avem că $\Sigma^\top \Sigma = \text{diag}(\sigma_0^2, \sigma_1^2, \dots, \sigma_{r-1}^2, 0, \dots, 0)$ unde r este rangul lui Σ . Ordonarea $\sigma_0^2 \geq \sigma_1^2 \geq \dots \geq \sigma_{r-1}^2$ rămâne valabilă pentru că valorile singulare originale sunt numere reale pozitive și deci $\mathcal{C}$ se poate scrie ca și

$$\mathcal{C} = V \left(\frac{1}{m-1} \Sigma^\top \Sigma \right) V^\top.$$

Notăm cu $\Lambda \stackrel{\text{not}}{=} \frac{1}{m-1} \Sigma^\top \Sigma$ și avem că

$$\Lambda = \text{diag} \left(\frac{\sigma_0^2}{m-1}, \frac{\sigma_1^2}{m-1}, \dots, \frac{\sigma_{r-1}^2}{m-1}, 0, \dots, 0 \right).$$

Acestea sunt valori proprii ale lui $\mathcal{C}$ (deoarece $\mathcal{C} = V \Lambda V^\top$), și depind de valorile singulare ale matricei centrate $\bar{X}$. $\square$

Remarcă. Din teorema Eckart-Young,

$$\min_{\substack{B \in \mathcal{M}_{m,n}(\mathbb{R}) \\ \text{rang } B=k}} \|\bar{X} - B\|_2 = \|\bar{X} - \bar{X}_k\|_2,$$

unde $\bar{X}_k = U \Sigma_k V$ cu notațiile obișnuite iar Σ_k reprezintă Σ unde numai primele k valori singulare sunt lăsate nenule. Acum folosind argumente care au mai apărut într-o demonstrație în acest proiect,

$$\|\bar{X} - \bar{X}_k\|_2 = \sigma_k = \sqrt{(m-1) \lambda_k}.$$

Am obținut în fine că eroarea aproximării matricei centrate depinde de ultima valoare singulară eliminată din matricea de covarianță.

Bibliografie

- [1] G. H. Golub, C. F. Van Loan – „*Matrix Computations*”, Johns Hopkins University Press, 2013
- [2] Cursul și laboratorul de calcul numeric L. N. Trefethen, D. Bau – „*Numerical Linear Algebra*”
- [3] Oxford College, Department of Mathematics and Computer Science – „*Bessel's Correction*”