


Utilizarea SVD pentru detectarea riscului de infarct miocardic

Universitatea din București,
Facultatea de Matematică și
Informatică

Rusănescu Gabriel (Grupa 161)
Sandu-Popa Eduard-Octavian (Grupa
164)




De ce analizăm datele medicale?

Bolile cardiovasculare sunt o cauză principală a mortalității la nivel global.

Medicii analizează simultan zeci de parametri (vârstă, istoric, analize de sânge). Apare redundanța informației.

Soluția propusă: Utilizarea algoritmului SVD pentru a extrage trăsăturile dominante și a comprima datele, facilitând diagnosticul.



Obiectivele proiectului

Implementare algoritmică: Scrierea algoritmilor Householder, QR și SVD exclusiv de la zero, fără funcții predefinite (`np.linalg.svd`).

Preprocesarea datelor: Curățarea și standardizarea unui set de date reale de risc cardiovascular.

Analiza erorilor: Evaluarea erorii matematice la aproximarea matricei prin rang inferior (k).

Vizualizare: Proiectarea pacienților într-un spațiu bidimensional (2D) pentru a observa separarea claselor de risc.

```

def fact_QR_HH(A):
    m, n = np.shape(A)
    R = np.copy(A).astype(float)
    Q = np.eye(m)

    for k in range(min(m, n)):
        x = R[k:, k].reshape(-1, 1)
        normax = np.linalg.norm(x)
        if normax < 1e-10:
            continue
        if x[0, 0] >= 0:
            sign = 1
        else:
            sign = -1
        alfa = -sign * normax
        e0 = np.zeros_like(x)
        e0[0, 0] = 1
        v = x - alfa * e0

        if np.linalg.norm(v) < 1e-10:
            continue
        numitor = (v.T @ v).item()
        if numitor < 1e-10:
            continue
        H_mic = np.eye(m - k) - 2 * (v @ v.T) / numitor
        Hk = np.eye(m)
        Hk[k:, k:] = H_mic

        R = Hk @ R
        Q = Q @ Hk

    return Q, R

```

Factorizarea QR

Householder

Scrierea algoritmilor Householder, QR, Tridiagonalizării și SVD exclusiv „de la zero”, fără funcții predefinite (`np.linalg.svd`) a fost realizată folosindu-i pe cei creați pentru laborator.

A fost făcută o corectare față de prezentarea din curs, pentru un nivel de stabilitate, am selectat ca semnul absolut al $(x[0, 0]) \cdot \text{norma}(x) \cdot e_0$ să fie pozitiv.

Restul algoritmilor au fost menținuți relativ asemănător cu cei din curs/laborator.

Calcul SVD:

k	Pondere:		Cumulativ:	
1	33.41	%	33.41	%
2	17.32	%	50.73	%
3	8.75	%	59.48	%
4	7.32	%	66.80	%
5	6.99	%	73.80	%
6	6.18	%	79.98	%
7	4.87	%	84.85	%
8	4.13	%	88.98	%
9	3.23	%	92.21	%
10	2.97	%	95.18	%
11	1.65	%	96.83	%
12	1.28	%	98.11	%
13	1.08	%	99.18	%
14	0.82	%	100.00	%

Timpe executie (varianta fara np.linalg): 0.2805 secunde

Calcul SVD:

k	Pondere:		Cumulativ:	
1	33.41	%	33.41	%
2	17.32	%	50.73	%
3	8.75	%	59.48	%
4	7.32	%	66.80	%
5	6.99	%	73.80	%
6	6.18	%	79.98	%
7	4.87	%	84.85	%
8	4.13	%	88.98	%
9	3.23	%	92.21	%
10	2.97	%	95.18	%
11	1.65	%	96.83	%
12	1.28	%	98.11	%
13	1.08	%	99.18	%
14	0.82	%	100.00	%

Timpe executie (varianta cu np.linalg): 0.0012 secunde


Reducerea Dimensionalității

Algoritmul implementează descompunerea SVD „de la zero” pentru a efectua reducerea dimensionalității unui set de date medicale, aproximând matricea de covarianță printr-un model de rang k care păstrează direcțiile de varianță maximă.

Formal, acesta transformă variabilele originale în componente principale ortogonale, permițând cuantificarea importanței fiecărei trăsături prin valorile singulare (σ) și ponderile asociate, facilitând astfel identificarea factorilor de risc dominanți.

(cardiovascularriskkeficient.py / cardiovascularriskkeficient
linalg.py)

Importanta Componentelor Principale



Preprocesarea datelor

Set de date: cardiovascular_risk_dataset.csv.

Codificarea variabilelor categorice: Transformarea textului în numere
(ex. fumat: Never=0, Former=1, Current=2).

Standardizarea: Esențială pentru a aduce toți parametrii (ex: varsta de 20, tensiune de 140 și colesterol de 200) la aceeași scară de magnitudine:
$$C_std = (x - medie) / deviatistandard$$

Algoritmul 1 - Tridiagonalizarea Householder

Scopul: Aducerea matricei de covarianță C la o formă tridiagonală T .

Se folosesc transformări de reflexie ortogonală.

Forma tridiagonală păstrează valorile proprii, dar accelerează dramatic pașii computaționali ulteriori.

$$H_v x = x - 2 \frac{v v^\top}{v^\top v} x$$

Algoritmul 2 - Iterația QR

Concept: Descompunerea repetată a matricei tridiagonale:

Algoritmul 2 Iterația QR

Subalgoritm *IterQR* ($A \in \mathcal{M}_{m,n}(\mathbb{R}), tol \in \mathbb{R}_{>0}, maxiter \in \mathbb{N}^*$)

$(Q, T) \leftarrow \text{HouseholderTri}(A); V \leftarrow Q$

Pentru $i \leftarrow 0, maxiter - 1$ execută

$E \leftarrow |T - \text{diag}(T)|$

$M \leftarrow \max_{i \neq j} T_{i,j}$

Dacă $M < tol$ atunci

Break

SfDacă

$(Q^*, R^*) \leftarrow \text{HouseholderQR}(T)$

$T \leftarrow R^* Q^*; V \leftarrow V Q^*$

SfPentru

Returnează (T, V)

SfSubalgoritm

Criteriul de oprire: Elementele extra-diagonale devin mai mici decât o toleranță fixată (10^{-10})

.Rezultat: Matricea converge spre o formă diagonală cu valorile proprii (λ_i). Produsul matricelor Q generează vectorii proprii.

Reconstrucția SVD și Gram-Schmidt

Concept: Descompunerea repetată a matricei tridiagonale:

$$\sigma_i = \sqrt{\lambda_i} \text{ a. } \hat{e}. \quad \sigma_0 \geq \sigma_1 \geq \dots \geq \sigma_{m-1} \geq 0$$

$$Av_i = u_i \sigma_i$$

Corecție numerică: Algoritmul Gram-Schmidt a fost implementat pentru a trata valorile singulare aproape nule ($< 10^{-10}$), asigurând ortogonalitatea completă și evitând erorile de tip „împărțire la zero”.

Semnificația Medicală (Analiza Ponderilor)

Componenta Principala 1 (corespunde lui σ_1):

bmi: 0.3600

systolic_bp: 0.3397

cholesterol_mg_dl: 0.3382

Componenta Principala 2 (corespunde lui σ_2):

age: 0.5849

systolic_bp: 0.3447

diastolic_bp: 0.3411


Componenta Principala 3 (corespunde lui σ_3):

sleep_hours: 0.5439

stress_level: 0.4108

diet_quality_score: 0.3342

Maparea Riscului Cardiovascular (2D)



Statistici și timpi de execuție

```
Timp executie (fara np.linalg): 0.1212 secunde
```

```
Statistici  
Total pacienti: 5500  
Pacienti OK (Low): 1838  
Pacienti cu risc (Medium/High): 3662
```

Se observă diferențele de timpi de execuție dintre cele două programe.

Statisticile de sănătate ale pacienților sunt la fel. Inițial, matricea de intrare avea 5501 linii (5500 pacienți) și 17 coloane (din care s-a renunțat la 3).

```
Timp executie (folosind np.linalg): 0.0033 secunde
```

```
Statistici  
Total pacienti: 5500  
Pacienti OK (Low): 1838  
Pacienti cu risc (Medium/High): 3662
```

(proiect fara linalg.py / proiect cu linalg.py)

Avantaje

Reducerea complexității (Dimensionalității): Datele medicale au adesea zeci de variabile (vârstă, tensiune, colesterol, greutate, istoric familial).

Aplicația reușește să comprime toate aceste informații în doar 2-3 "Componente Principale". Acest lucru face setul de date mult mai ușor de gestionat.

Identificarea factorilor de risc dominanți: Prin funcția care afișează ponderile (afisponderi), aplicația arată exact care variabile clinice trag cel mai tare / domină în formarea riscului cardiovascular. Nu trebuie ghicit.

Avantaje

Filtrarea zgomotului: Prin eliminarea componentelor cu valori singulare foarte mici (ultimele din tabel), aplicația aruncă de fapt erorile de măsurare și „zgomotul” statistic, păstrând doar tiparele puternice din date.

Dezavantaje

Pierderea interpretabilității directe (cel mai mare dezavantaj): Un medic înțelege perfect ce înseamnă „Tensiune arterială = 140”. Dar Componenta Principală 1 este o ecuație matematică (ex: $0.5 \times \text{Tensiune} + 0.3 \times \text{Vârstă} + 0.1 \times \text{Colesterol}$). Nu există o unitate de măsură clinică pentru „Componenta 1”, ceea ce face rezultatul mai greu de explicat unui pacient.

Sensibilitatea la anomalii (Valori extreme): PCA se bazează pe varianță (ridicarea distanțelor la pătrat). Dacă în tabel există pacienți cu date introduse greșit sau cu valori extrem de mari/anormale, aceștia vor trage puternic axele spre ei, distorsionând întregul model.

Dezavantaje

Varianța maximă nu înseamnă neapărat predicție bună: PCA caută direcțiile în care datele se împrăștie cel mai mult. Dar este posibil ca împrăștierea maximă să fie dată de vârstă, în timp ce riscul real de infarct să fie definit de o variabilă mai subtilă (cu varianță mai mică), pe care PCA o aruncă în componentele inferioare.

Concluzii

Implementare robustă: Algoritmii numerici de la zero (Householder, QR) sunt perfect funcționali pe un set de date reale.

Eficiență: Analiza cu SVD a eliminat redundanța, extrăgând factorii determinanți ai riscului de infarct.

Transparență: Folosirea matricei V ne permite să traducem matematica abstractă direct în parametri medicali utili medicilor.

Bibliografie

G.H. Golub, C.F. Van Loan – Matrix Computations, Johns Hopkins University Press, 2013.

Cursul și laboratorul de calcul numeric

L.N. Trefethen, D. Bau – Numerical Linear Algebra

Bessel's Correction – Oxford College, Department of Mathematics and Computer Science

I.T. Jolliffe – Principal Component Analysis, Second Edition

<https://www.kaggle.com/datasets/vishardmehta/heart-risk-progression-dataset>

Vă mulțumim pentru atenție!

